

Solar Classifier: Detecção e Classificação de Regiões Ativas Solares com YOLOv11

Da imagem magnética bruta à classificação de Mount Wilson

Paulo Ricardo Rotband Rangel

6 de julho de 2026

Sumário

- 1 Motivação
- 2 Classificação de Mount Wilson
- 3 YOLO: Detecção de Objetos
- 4 Pipeline do Projeto
- 5 Avaliação
- 6 Resultados (run solar_ar-16)
- 7 Referências
- 8 Conclusão

Por que classificar Regiões Ativas?

- **Regiões Ativas (ARs):** áreas do Sol com forte concentração de campo magnético, visíveis como manchas solares (*sunspots*).
- São a origem de **erupções solares (flares)** e **ejeções de massa coronal (CMEs)**.
- Eventos intensos podem afetar:
 - Satélites e comunicações de rádio;
 - Redes elétricas (tempestades geomagnéticas);
 - Missões espaciais tripuladas.
- **Ideia central do projeto:** quanto mais complexa a topologia magnética de uma AR, maior a probabilidade de flares fortes.
- **Objetivo:** automatizar a **deteccção** (onde está a AR) e a **classificação** (quão complexa ela é) usando visão computacional.

O que é a Classificação de Mount Wilson?

- Criada no **Observatório de Mount Wilson** para descrever a **complexidade magnética** de uma região ativa.
- Baseia-se na distribuição espacial das polaridades magnéticas (positiva/negativa) dentro da mancha.
- Quanto mais misturadas e próximas as polaridades opostas estiverem, maior o **gradiente magnético** e maior a energia disponível para reconexão magnética → **flares**.
- É o esquema de classificação usado pelo **NOAA/SWPC** para previsão de clima espacial até hoje.

As Quatro Classes Usadas no Projeto

Classe	Nome	Padrão	Interpretação física
0	Alpha	Unipolar	Uma única polaridade dominante; baixa complexidade.
1	Beta	Bipolar simples	Duas polaridades bem separadas por uma linha de inversão clara.
2	Beta-Gamma	Bipolar complexo	Polaridades misturadas/entrelaçadas; linha de inversão irregular.
3	Beta-Gamma-Delta	Complexidade máxima	Polaridades opostas compartilham a mesma penumbra (<i>delta spot</i>); altíssima probabilidade de flares X/M.

Alpha → Beta → Beta-Gamma → Beta-Gamma-Delta


baixo risco

alto risco de flares

O que é YOLO (You Only Look Once)?

- Família de redes neurais para **detecção de objetos em tempo real**.
- Diferente de abordagens em duas etapas (ex.: R-CNN, que primeiro propõe regiões e depois classifica), o YOLO faz tudo em **uma única passada** pela rede.
- A imagem é tratada como um problema único de **regressão**: a rede prevê simultaneamente, para cada região da imagem:
 - as coordenadas da **caixa delimitadora** (bounding box);
 - a **confiança** de haver um objeto ali;
 - a **classe** do objeto.
- Resultado: extremamente rápido, adequado tanto para vídeo em tempo real quanto para varreduras em lote de imagens científicas.

Arquitetura Geral: Backbone → Neck → Head




- **Backbone:** convoluções profundas que resumem a imagem em mapas de características.
- **Neck:** combina mapas de diferentes resoluções (útil pois uma AR pode ocupar poucos ou muitos pixels).
- **Head:** camada final que gera as previsões por região da imagem (*anchor-free* nas versões mais recentes).

Por que YOLOv11?

- Versão mais recente da família YOLO (Ultralytics), com melhorias sobre YOLOv8:
 - Blocos convolucionais mais eficientes (menos parâmetros para a mesma precisão);
 - Módulos de atenção espacial no *neck*, melhorando a detecção de objetos pequenos;
 - Detecção *anchor-free*: não depende de caixas-âncora pré-definidas, generalizando melhor para objetos de formato/tamanho variável — como manchas solares.
- Disponível em múltiplos tamanhos: n, s, m, l, x — trade-off entre velocidade e acurácia.
- **Configuração padrão do projeto:** yolo11m.pt (*medium*, ~20M parâmetros), pré-treinado no **COCO**, ajustado (*fine-tuning*) para 4 classes solares.
- A execução solar_ar-16 (seção de Resultados) usou yolo11n.pt (*nano*) em CPU, variante mais leve para validar o pipeline mais rapidamente.

Visão Geral do Pipeline de Dados



Fluxo linear e modular: dados astronômicos brutos → dataset pronto para Deep Learning.

Etapa 1 — Aquisição de Dados (download.py)

- Fonte: **JSOC** (Joint Science Operations Center), série `hmi.M_720s` — magnetogramas de linha de visão do instrumento **HMI/SDO**.
- **Protocolo de exportação em 3 etapas** (via HTTP):
 - ➊ **Request**: solicita a exportação de um intervalo de datas;
 - ➋ **Polling**: aguarda o JSOC processar a solicitação;
 - ➌ **Streaming**: baixa os arquivos FITS resultantes.
- **Estratégia de implementação**:
 - Assíncrona, usando `aiohttp`;
 - Grandes períodos são divididos em blocos de **90 dias** para evitar timeouts no servidor.

Etapa 2 — Pré-processamento (`preprocess.py`)

Arquivos FITS não podem ser lidos diretamente por redes neurais — esta etapa converte física em imagem.

- **Correção de orientação:** verifica e corrige o ângulo `CR0TA2`, garantindo Norte solar sempre para cima.
- **Normalização magnética:**
 - Campo magnético (Gauss) clipado em ± 1000 G;
 - Mapeamento linear para `uint8` `[0, 255]`: Sol calmo (0 G) $\rightarrow$ cinza médio (≈ 127).
- **Redimensionamento:** imagens levadas a 1024×1024 px com interpolação de **Lanczos**, preservando manchas pequenas.
- **Sidecar WCS** (*World Coordinate System*): arquivo `.json` com parâmetros de escala/referência — necessário para converter coordenadas do HEK (arcsegundos) em pixels da imagem redimensionada.

Detalhe Técnico: Por que Interpolação de Lanczos?


- As imagens nativas do HMI têm 4096×4096 px ($\approx 0,504''/\text{pixel}$) — o redimensionamento para 1024×1024 é um **downsampling** de $4\times$.
- Métodos simples (*nearest-neighbor*, bilinear) fazem uma média local ingênua: borram ou causam *aliasing* em detalhes pequenos — exatamente o problema, pois manchas isoladas e a **linha de inversão de polaridade** de um *delta-spot* podem ocupar poucos pixels.
- **Lanczos** usa um kernel de *sinc* janelado:

$$L(x) = \begin{cases} \text{sinc}(x) \text{sinc}\left(\frac{x}{a}\right), & |x| < a \\ 0, & \text{caso contrário} \end{cases} \quad \text{sinc}(x) = \frac{\sin(\pi x)}{\pi x}$$

com $a = 3$ (Lanczos-3, padrão do Pillow Image.LANCZOS).


- **Trade-off**: é mais caro computacionalmente e pode gerar leve *ringing* (overshoot) em bordas de altíssimo contraste — aceitável aqui, pois preservar a morfologia da mancha importa mais do que suavidade visual.
- Prática comum em processamento de imagens astronômicas (ex.: `reproject`, `astropy`) por preservar melhor conteúdo de alta frequência do que bicúbica/bilinear.

Exemplo Real: Magnetograma Pré-processado



Magnetograma HMI real do dataset do projeto, após correção de CR0TA2, normalização ± 1000 G $\rightarrow$ uint8 e redimensionamento para 1024×1024 px. Cinza médio = Sol calmo; regiões claras/escuras = polaridades magnéticas opostas.

Exemplo Real: Labels (Ground Truth) sobre o Magnetograma



Mesma imagem com as caixas YOLO reais do dataset, geradas a partir dos eventos do HEK (`src/labels.py`) e sobrepostas via `src/debug_overlay.py` para checagem visual da geometria.

Etapa 3 — Geração de Labels (labels.py)

As *ground truths* vêm do **HEK** (Heliophysics Event Knowledgebase).

- **Estratégia de consulta:** uma query HTTP **por dia** (não por imagem), eventos armazenados em cache e associados às imagens dentro de uma janela de ± 30 minutos.
- **Geometria da bounding box** — ordem de prioridade:
 - 1 **SHARP**: fornece a extensão real do *patch* magnético (melhor fonte);
 - 2 **SPoCA**: fallback via proximidade espacial;
 - 3 **Estimativa por área**: último recurso, baseada na área da região em **MSH** (*Millionths of Solar Hemisphere*).
- Classes finais mapeadas via MTWILSON_MAP: $\alpha \rightarrow 0$, $\beta \rightarrow 1$, $\beta\gamma/\gamma/\beta\delta \rightarrow 2$, $\beta\gamma\delta \rightarrow 3$.

SHARP — *Space-weather HMI Active Region Patches* (Bobra et al. 2014).

- Módulo automático do pipeline HMI que **detecta e rastreia** concentrações de campo magnético vetorial ao longo de todo o trânsito da AR pelo disco (~ 2 semanas), a cada 12 minutos.
- Gera dois tipos de recorte por região: CCD (pixel nativo) e CEA (projeção *Cylindrical Equal-Area*, que remove o efeito de escorço perto do limbo solar).
- Os metadados trazem diretamente a **extensão heliográfica real** do *patch* rastreado (não uma estimativa) — por isso é a fonte prioritária de bounding box no projeto.
- Cada SHARP carrega o número NOAA da AR, usado para casar com os eventos de classificação Mount Wilson do HEK.

SPoCA — *Spatial Possibilistic Clustering Algorithm* (Verbeeck et al. 2013).

- Algoritmo de **segmentação não supervisionada**, originalmente criado para detectar Regiões Ativas e Buracos Coronais em imagens EUV (SDO/AIA), também usado para alimentar o HEK com posições de AR.
- Baseado em *possibilistic c-means* — uma variante *fuzzy* do k-means: cada pixel recebe um **grau de pertencimento** a um cluster, em vez de um limiar rígido; mais adequado a bordas difusas de estruturas solares.
- **Uso no projeto**: quando não há SHARP correspondente (ex.: AR ainda sem número NOAA, ou lacuna na cobertura), usa-se a detecção SPoCA mais próxima espacialmente — dá a *posição*, mas não necessariamente a geometria exata da bbox.

Etapa 4 — Treinamento (`train.py`)

- Arquitetura: **YOLOv11m** (medium), com **transfer learning** a partir de pesos pré-treinados no **COCO**.
- O *backbone* já sabe detectar bordas/texturas/blobs genéricos — a rede só precisa adaptar a *head* para as 4 classes solares.
- **Otimização:**
 - *Cosine Learning Rate Schedule* (`cos_lr=True`) — decaimento suave da taxa de aprendizado;
 - *Early stopping* (`patience=20`) — evita overfitting em datasets solares pequenos.
- **Hardware:** suporte a **CUDA** (Nvidia) e **DirectML** (AMD GPU, via `torch-directml`), com fallback para CPU multi-thread.

Restrições Físicas de Augmentation

Magnetogramas não são fotos comuns — augmentations padrão podem gerar dados **fisicamente impossíveis**.

- `fliplr = 0` (sem espelhamento horizontal):
 - Inverteria a orientação Leste-Oeste e a **Lei de Hale** (polaridade líder/seguidora por hemisfério).
- `flipud = 0` (sem espelhamento vertical):
 - Inverteria Norte/Sul e a **Lei de Joy**, que dita a inclinação estatística dos grupos bipolares em relação ao equador.
- `hsv_h = 0, hsv_s = 0` (sem matiz/saturação):
 - Dados são grayscale de 1 canal — matiz e saturação não têm significado físico.
- `hsv_v = 0.02`: leve jitter de brilho mantido, simulando variações de calibração do HMI sem distorcer a polaridade.

Detalhe Técnico: Lei de Hale (Polaridade Magnética)

- Descrita por Hale, Ellerman, Nicholson & Joy (1919) — o mesmo artigo que origina a classificação de Mount Wilson.
- Em grupos bipolares, a mancha **líder** (mais a oeste, no sentido da rotação) tem sempre a **mesma polaridade** em todo um hemisfério solar durante um dado ciclo de 11 anos; o hemisfério oposto tem polaridade líder invertida.
- Esse padrão **se inverte** a cada novo ciclo de 11 anos — por isso o ciclo magnético completo do Sol (*ciclo de Hale*) dura ≈ 22 anos.
- **Consequência para o augmentation** ($\text{flip}lr=0$): espelhar horizontalmente troca a mancha líder pela seguidora, o que equivale a simular o hemisfério errado ou a metade errada do ciclo solar — uma combinação que praticamente nunca ocorre na natureza. Treinar com esses dados ensinaria ao modelo um padrão de polaridade fisicamente impossível.

Detalhe Técnico: Lei de Joy (Inclinação dos Grupos)

- Relatada por Alfred Joy no mesmo artigo de 1919: grupos bipolares não são alinhados perfeitamente Leste-Oeste — são **inclinados**, com a mancha líder ligeiramente mais próxima do equador que a seguidora.
- O ângulo de inclinação **cresce com a latitude** heliográfica da região (tendência estatística, com dispersão considerável região a região).
- **Origem física** (modelo de Babcock–Leighton): a força de **Coriolis** atua sobre o tubo de fluxo magnético torcido enquanto ele ascende por flutuação através da zona de convecção, torcendo o par de manchas nesse sentido preferencial.
- **Consequência para o augmentation** ($\text{flipud}=0$): espelhar verticalmente inverte Norte/Sul e, com isso, o sinal dessa inclinação estatística — ensinaria ao modelo uma relação inclinação-latitude que viola a física do dínamo solar real.

- **mAP50** (*mean Average Precision @ IoU 0.50*):
 - Padrão em detecção de objetos solares/sensoriamento remoto; considera uma detecção correta se a sobreposição (IoU) com a caixa real for $\geq 50\%$.
- **mAP50-95**:
 - Média sobre limiares de IoU de 0.50 a 0.95 (passo 0.05) — métrica estilo COCO, mais rigorosa quanto à precisão de localização.
- **IoU** (*Intersection over Union*):

$$\text{IoU} = \frac{\text{Área de Interseção}}{\text{Área de União}}$$

entre a caixa prevista e a caixa real (*ground truth*).

Tabela de Referências Técnicas


Conceito	Referência no código	Significado
Séries HMI	src/download.py	Dados de magnetometria do SDO.
WCS Projection	src/preprocess.py → sidecar	Coordenadas esféricas → pixels.
Mount Wilson	src/labels.py → MTWILSON_MAP	Escala de complexidade magnética.
Lei de Joy	src/train.py → flipud=0	Regra física da inclinação das ARs.
mAP50	src/train.py → evaluate()	Métrica de precisão de detecção.

Configuração da Execução solar_ar-16

Parâmetro	Valor
Modelo	yolo11n.pt (nano, COCO pré-treinado)
Dispositivo	CPU (sem AMP)
Imagem	1024 × 1024 px
Batch	8
Épocas configuradas	100 (patience=20, cos_lr=True)
Épocas efetivamente rodadas	24
Augmentation	fliplr=0, flipud=0, hsv_h=hsv_s=0


Fonte: *runs/solar_ar-16/args.yaml* e *results.csv*.

Distribuição Real das Classes no Treino




Instâncias por classe: Alpha 571 · Beta 873 · Beta-Gamma 5723 · Beta-Gamma-Delta 5090.
Forte **desbalanceamento** a favor das classes mais complexas — ponto de atenção para trabalhos futuros.

Evolução do mAP ao Longo do Treino



Fonte: `runs/solar_ar-16/results.csv`. Alta variância entre épocas — esperado em dataset pequeno.

Perda de Treino vs. Validação



Fonte: `runs/solar_ar-16/results.csv` (soma de `box_loss+cls_loss+dfl_loss`).

A perda de treino cai de forma suave e monotônica; a de validação oscila fortemente entre épocas — sinal de **overfitting** e de um conjunto de validação pequeno demais para estabilizar a métrica.

Melhor Checkpoint (best.pt)

Métrica (época 18)	Valor
Precision	0.251
Recall	0.398
mAP50	0.199
mAP50-95	0.115

Leitura honesta dos resultados:

- Modelo nano em CPU, com poucas épocas — resultado é uma **prova de conceito**, não um modelo de produção.
- Grande variância de métricas entre épocas sugere dataset ainda pequeno para o modelo estabilizar.
- Desbalanceamento de classes (slide anterior) provavelmente penaliza Alpha e Beta na precisão.
- Próximo passo natural: mais dados, yolov11m/1 em GPU, e re-balanceamento de classes.

- SDO/HMI — Instrument overview:
sdo.gsfc.nasa.gov/mission/instruments/hmi.php
- JSOC — Joint Science Operations Center (acesso aos dados HMI):
jsoc.stanford.edu
- HEK — Heliophysics Event Knowledgebase:
lmsal.com/hek
Hurlburt, N. et al. (2012). *Heliophysics Event Knowledgebase for the Solar Dynamics Observatory (SDO) and Beyond*. Solar Physics, 275, 67–78.
- SHARP — Space-weather HMI Active Region Patches:
Bobra, M. G. et al. (2014). *The Helioseismic and Magnetic Imager (HMI) Vector Magnetic Field Pipeline: SHARPs*. Solar Physics, 289, 3549–3578.

- Classificação magnética de Mount Wilson (origem):
Hale, G. E., Ellerman, F., Nicholson, S. B., & Joy, A. H. (1919). *The Magnetic Polarity of Sun-Spots*. *The Astrophysical Journal*, 49, 153.
- Lei de Joy / Lei de Hale — inclinação e polaridade de grupos bipolares:
van Driel-Gesztelyi, L. & Green, L. M. (2015). *Evolution of Active Regions*. *Living Reviews in Solar Physics*, 12, 1.
- Esquema estendido (McIntosh), usado operacionalmente junto ao Mount Wilson:
McIntosh, P. S. (1990). *The classification of sunspot groups*. *Solar Physics*, 125, 251–267.
- NOAA / Space Weather Prediction Center (previsão operacional de clima espacial):
swpc.noaa.gov

- Artigo original do YOLO:
Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). *You Only Look Once: Unified, Real-Time Object Detection*. CVPR 2016. arxiv.org/abs/1506.02640
- Documentação oficial YOLOv11 (Ultralytics):
docs.ultralytics.com/models/yolo11
- Código-fonte Ultralytics:
github.com/ultralytics/ultralytics
- Métricas de detecção (mAP, IoU) — protocolo COCO:
cocodataset.org/#detection-eval

- Pipeline completo e reprodutível: **JSOC** → **FITS** → **PNG/WCS** → **Labels YOLO** → **Modelo treinado**.
- Combina **visão computacional moderna** (YOLOv11) com **restrições físicas do domínio** (Lei de Joy, Lei de Hale, orientação solar).
- Classificação automática segundo o esquema de **Mount Wilson**, usado operacionalmente pelo NOAA para previsão de clima espacial.
- Resultado inicial (solar_ar-16, YOLOv11n/CPU): $\text{mAP}_{50} \approx 0.20$ — prova de conceito do pipeline ponta a ponta, não um modelo final.
- Próximos passos: mais dados históricos, modelos maiores (m/l) em GPU, e correção do desbalanceamento de classes.

Perguntas?